Regional Logistics Transfers

מרצה: ד"ר עמיחי פיינסקי

קבוצה 27

לידיה סלאמה (326588688) / **רובא חמוד** (326575362) / **פארס אבו רחאל** (214643595)



תקציר מנהלים

בפרויקט נבנה מודל סיווג בינארי לחיזוי האם העברת מטען תתעכב ביותר מ-30 דקות ביחס לזמן ההגעה המתוכנן. בסיס הנתונים כלל 51,056 רשומות אימון ו-7,555 רשומות מבחן. משתנה המטרה היה is_delayed, כאשר 1 מייצג איחור משמעותי ו-0 מייצג אי-איחור משמעותי. שיעור האיחורים בנתוני האימון היה 13.99%, ולכן הבעיה אינה מאוזנת לחלוטין.

לאחר חקר נתונים ועיבוד מקדים נבחנו ארבעה מודלים: Logistic Regression, Decision Tree, Random Forest ו-Linear SVM. כל המודלים השיגו ROC-AUC גבוה מאוד על סט הוולידציה. המודל הסופי שנבחר להגשה היה Random Forest, משום שהוא הציג ביצועי AUC גבוהים מאוד ויכולת הכללה יציבה, תוך שימוש באנסמבל עצים ובאיזון מחלקות.

חקר נתונים ותובנות מרכזיות

בשלב האקספלורציה נבדקו התפלגות משתנה המטרה, ערכים חסרים, זמני יציאה, ספקים לוגיסטיים, אזורי מקור ויעד, עיכובים צפויים, מרחקי מסלול ומשתנים פנימיים אנונימיים. הנתונים הראו כי קיימים דפוסים ברורים הקשורים לסיכוי לעיכוב.

ראשית, נבדקה התפלגות משתנה המטרה. נמצא כי רק 13.99% מההעברות סווגו כמאחרות, ולכן קיימת אי-סימטריה בין שתי המחלקות. מסיבה זו, הסתמכות על Accuracy בלבד אינה מספיקה, ולכן בהמשך נעשה שימוש במדד ROC-AUC. התפלגות זו מוצגת בנספח א'.

נמצאו הבדלים בין ספקים ואזורים. לדוגמה, בקרב ספקים עם לפחות 100 תצפיות, הספקים B6 ו-F9 הגיעו לשיעורי איחור של כ-23.5% וכ-21.9%, בעוד שספקים כמו MQ, HA ו-WN היו נמוכים יותר, בטווח של כ-9.4% עד 11.4%. ממצא זה מצביע על כך שלספק הלוגיסטי עשויה להיות השפעה על הסיכוי לעיכוב. ההשוואה בין ספקים ואזורים מוצגת בנספח ב'.

שעת היציאה המתוכננת נמצאה כמשתנה משמעותי. שיעור האיחור עלה מכ-7.0% בשעה 07:00 לכ-20.7% בשעה 19:00. כלומר, העברות המתוכננות לשעות מאוחרות יותר ביום נמצאו בעלות סיכון גבוה יותר לאיחור משמעותי. מגמה זו מוצגת בנספח ג'.

עיכוב יציאה צפוי היה אחד המסבירים החזקים ביותר. כאשר expected_dispatch_delay_minutes היה מעל כ-19 דקות, שיעור האיחור הגיע לכ-64.7%, לעומת כ-1% עד 4% בלבד בקבוצות הנמוכות. בנוסף, הקורלציה בין expected_dispatch_delay_minutes לבין is_delayed הייתה כ-0.598. כלומר, ככל שעיכוב היציאה הצפוי גבוה יותר, כך עולה באופן משמעותי ההסתברות לעיכוב הגעה משמעותי. ממצא זה מוצג בנספח ד'.

לעומת זאת, מרחק המסלול לא נראה משמעותי במיוחד. שיעורי האיחור לפי חמישוני route_distance_miles היו קרובים מאוד, כ-13.6% עד 14.5%, והקורלציה עם משתנה המטרה הייתה כמעט אפסית. לכן, נראה שמרחק המסלול לבדו אינו מסביר מרכזי לחיזוי עיכובים. ניתוח זה מוצג בנספח ה'.

נמצאו קורלציות חזקות בין סוגי עיכובים שונים. לדוגמה, expected_dispatch_delay_minutes היה בקורלציה של כ-0.668 עם expected_provider_delay_minutes, ובקורלציה של כ-0.635 עם expected_previous_transfer_delay_minutes. הדבר מצביע על קשר בין מקורות עיכוב שונים במערכת הלוגיסטית. מטריצת הקורלציות מוצגת בנספח ו'.

חלק מהמשתנים האנונימיים תרמו מידע משמעותי. לדוגמה, internal_metric_a העלה את שיעור האיחור מכ-9.9% בחמישון הנמוך לכ-25.4% בחמישון הגבוה. לעומת זאת, internal_operational_score נראה חלש יחסית. לכן, גם כאשר משמעותם העסקית של משתנים אלו אינה ידועה, חלקם עדיין מועילים לחיזוי. ניתוח המשתנים האנונימיים מוצג בנספח ז'.

עיבוד מקדים והנחות עבודה

העיבוד המקדים בוצע באמצעות Pipeline וColumnTransformer- של sklearn, כדי להבטיח שאותם צעדים יילמדו רק על נתוני האימון ויוחלו באותו אופן על הvalidation- ועל ה,test- ללא דליפת מידע.

בוצע ניקוי קטגוריות באמצעות strip לערכים טקסטואליים כדי לטפל ברווחים מיותרים. לדוגמה, מספר הערכים הייחודיים באזורי מקור ויעד ירד לאחר הניקוי, ולכן זה היה שלב חשוב לפני .One-Hot Encoding

בשלב הנדסת המסבירים, זמני HHMM הומרו לדקות מהחצות. בנוסף נבנו dispatch_hour ו,arrival_hour- נוספו ייצוגים מחזוריים sin וcos- לזמני היום, חושב planned_clock_travel_minutes, ונבנו סכומי עיכובים צפויים, אינטראקציה בין מזג אוויר לעומס רשת, ומהירות מתוכננת משוערת.

המשתנה operation_date הוסר כמשתנה גולמי, משום שסט האימון כלל תאריכים 01.04.2024-07.04.2024 ואילו הtest- היה בתאריך 08.04.2024. שימוש ישיר בתאריך עלול לגרום להתאמת יתר לתקופת האימון.

לגבי ערכים חסרים, למשתנים מספריים בוצע מילוי לפי חציון, ולמשתנים קטגוריאליים לפי הערך השכיח. בנוסף, בSimpleImputer- למספריים הופעל add_indicator=True כדי לשמר מידע על עצם החוסר.

נמצאו ערכים חריגים במספר משתנים, במיוחד במשתני עיכוב. במקום למחוק רשומות, הוחל Winsorization לפי אחוזונים 1% ו-99%, משום שערכי קצה יכולים לייצג אירועים תפעוליים אמיתיים.

לאחר טיפול בחריגים ובחוסרים, המשתנים המספריים עברו .StandardScaler הדבר חשוב במיוחד עבור Logistic Regression ו,Linear SVM- הרגישים לסקאלות שונות.

המשתנים הקטגוריאליים הומרו באמצעות One-Hot Encoding עם ,"handle_unknown="ignore כדי להתמודד גם עם קטגוריות אפשריות שמופיעות בtest- ולא הופיעו באימון.

לאחר הנדסת המסבירים והקידוד התקבלו 257 מאפיינים לאחר עיבוד. ממד זה סביר לפרויקט, בעיקר משום שרוב הגידול נובע מקידוד קטגוריות, והמודלים שנבחרו מסוגלים להתמודד עם ממד כזה

דילמות והחלטות במהלך העבודה

במהלך העבודה היו מספר דילמות מרכזיות.

הדילמה הראשונה הייתה האם להשתמש ב-date_operation כמשתנה מסביר. מצד אחד, תאריך יכול להכיל מידע על דפוסים יומיים. מצד שני, סט ה-test שייך ליום חדש שלא הופיע ב-train. לכן שימוש בתאריך גולמי עלול להוביל להתאמת יתר ולא ללמידה אמיתית של דפוסים כלליים. בעקבות זאת הוחלט להסיר את date_operation כמשתנה גולמי.

הדילמה השנייה הייתה כיצד להתמודד עם ערכים חסרים. נשקלה אפשרות להשתמש ב-KNN Imputation, אך שיטה זו עלולה להיות כבדה חישובית עבור סט נתונים גדול יחסית. בנוסף, חלק מהחוסרים עצמם עשויים לשאת מידע. לכן נבחר שילוב פשוט ויציב יותר: מילוי חציון למספריים, מילוי שכיח לקטגוריאליים, והוספת אינדיקטור לערכים חסרים.

הדילמה השלישית הייתה בחירת רמת המורכבות של עצי ההחלטה. מודלים כמו Decision Tree ו-Random Forest יכולים להגיע לביצועים גבוהים מאוד, אך גם עלולים לבצע Overfitting. לכן נבחרו הגבלות כמו depth_max, וכן ערכים גבוהים יחסית של leaf_samples_min. לדוגמה, ב-Decision Tree נבחר leaf_samples_min=80, כדי למנוע פיצולים קטנים מדי שמתאימים את עצמם לרעש בנתוני האימון.

הדילמה הרביעית הייתה בחירת המודל הסופי. למרות ש-Decision Tree קיבל ממוצע Cross Validation מעט גבוה יותר, נבחר בסוף Random Forest, משום שהוא מבוסס על אנסמבל עצים ולכן יציב יותר ופחות תלוי בעץ יחיד ובפיצולים ספציפיים. כלומר, ההחלטה לא התבססה רק על ההפרש הקטן ב-AUC, אלא גם על שיקול של יכולת הכללה.

מודלים שנבחנו והיפר-פרמטרים

בהתאם לדרישות הפרויקט נבחר מודל בסיסי אחד ושלושה מודלים מתקדמים. כל המודלים אומנו על אותו split מרובד: 80% אימון ו-20% ולידציה.

מודל	היפר-פרמטרים מרכזיים	רציונל
Logistic Regression	max_iter=300, solver='liblinear', class_weight='balanced'	קו בסיס לינארי, מתאים לסיווג בינארי ומאזן את המחלקות.
Decision Tree	max_depth=8, min_samples_leaf=80, class_weight='balanced'	עץ החלטה פרשני; הגבלת עומק וגודל עלה מפחיתה Overfitting.
Random Forest	n_estimators=50, max_depth=12, min_samples_leaf=40, class_weight='balanced_subsample'	אנסמבל עצים עם הגבלת מורכבות ואיזון מחלקות.
Linear SVM	C=0.5, max_iter=4000, class_weight='balanced'	מודל לינארי חזק לאחר נרמול וקידוד קטגוריות.

הערכת ביצועים ויכולת הכללה

מדד ההערכה המרכזי היה ROC-AUC, משום שהוא מתאים לבעיית סיווג בינארי ובעיקר לנתונים שבהם המחלקות אינן מאוזנות. בנוסף נבדקה מטריצת בלבול עבור Random Forest, ובוצע Stratified 5-Fold Cross Validation לכל המודלים.

מודל	AUC אימון	AUC ולידציה	ממוצע AUC ב-5-Fold	פער אימון-ולידציה
Decision Tree	0.999727	0.999329	0.999121	0.000398
Random Forest	0.999212	0.999327	0.998859	-0.000115
Logistic Regression	0.998239	0.997908	0.997867	0.000330

מודל	AUC אימון	AUC ולידציה	ממוצע AUC ב-5-Fold	פער אימון-ולידציה
Decision Tree	0.999727	0.999329	0.999121	0.000398
Linear SVM	0.998265	0.997900	0.997827	0.000366

תוצאות ה-AUC גבוהות מאוד בכל המודלים, מה שמראה כי קיימים מסבירים חזקים מאוד בנתונים, בעיקר משתני העיכוב הצפוי והעיכוב הקודם. עץ ההחלטה קיבל את ממוצע ה-CV הגבוה ביותר, אך ההפרשים בין Decision Tree לבין Random Forest זניחים מאוד. לכן נבחר Random Forest כמודל סופי, מתוך העדפה למודל יציב יותר המבוסס על אנסמבל.

מטריצת הבלבול של Random Forest על סט הוולידציה הייתה: True Negatives 8,677, True Positives 1,411, False Positives 106 ו-False Negatives 18. כלומר, המודל זיהה נכון את רוב ההעברות המאחרות ואת רוב ההעברות שאינן מאחרות. עבור המחלקה המאחרת, ה-recall היה כ-98.7% וה-precision היה כ-93.0%. מטריצת הבלבול מוצגת בנספח ח'.

בדיקת Overfitting התבססה על השוואת AUC באימון מול AUC בוולידציה. הפערים היו קטנים מאוד, סביב 0.0001 עד 0.0004, ולכן לא נמצאה עדות משמעותית ל-Overfitting. עם זאת, משום שערכי ה-AUC גבוהים מאוד, נבדקה גם האפשרות לדליפת מידע. כדי לצמצם סיכון זה, לא נעשה שימוש במזהה id_transfer כמשתנה מסביר, והערכת המודלים בוצעה על סט ולידציה ועל Cross Validation. עקומות ה-ROC לפי folds מוצגות בנספח ט'.

פרדיקציה על קובץ הtest-

לאחר בחירת המודל הסופיRandom Forest , אומן מחדש על כל נתוני האימון המתויגים כדי לנצל את כל המידע הזמין. לאחר מכן הופקה לכל רשומה בtest- הסתברות להיות is_delayed=1.

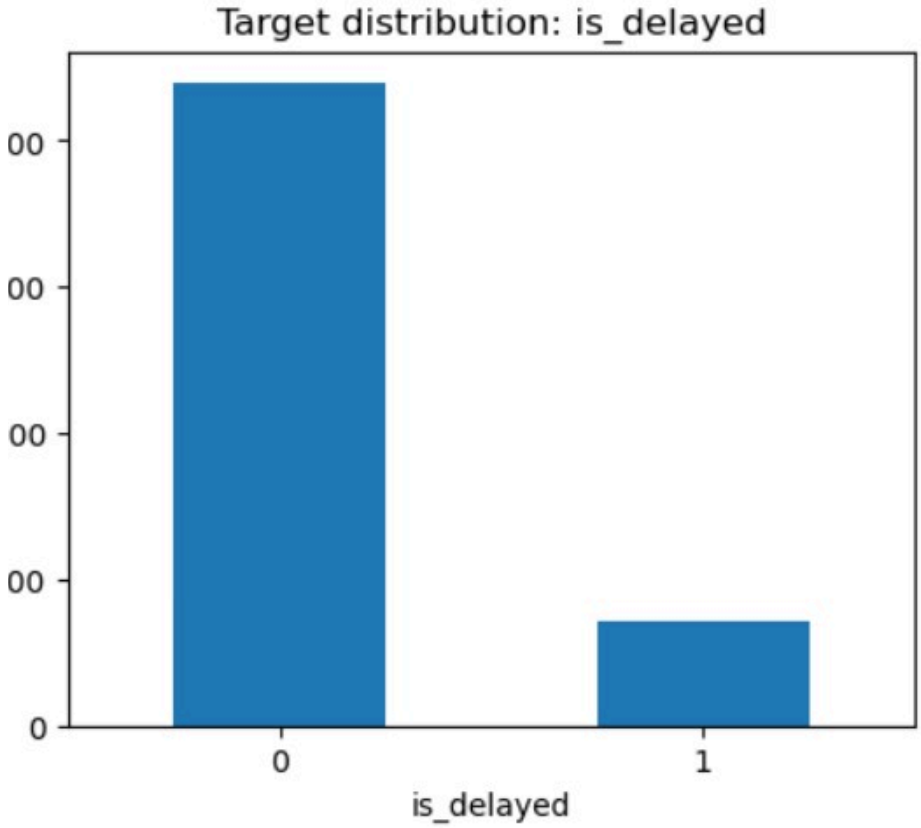
קובץ ההגשה שנוצר הוא group_NUMBER_Submission.csv וכולל שתי עמודות בלבדtransfer_id : ו.predict_prob- הקובץ כולל 7,555 שורות, בדיוק כמספר הרשומות ב,test- וטווח ההסתברויות הוא 0.002848 עד 0.997062.

סיכום

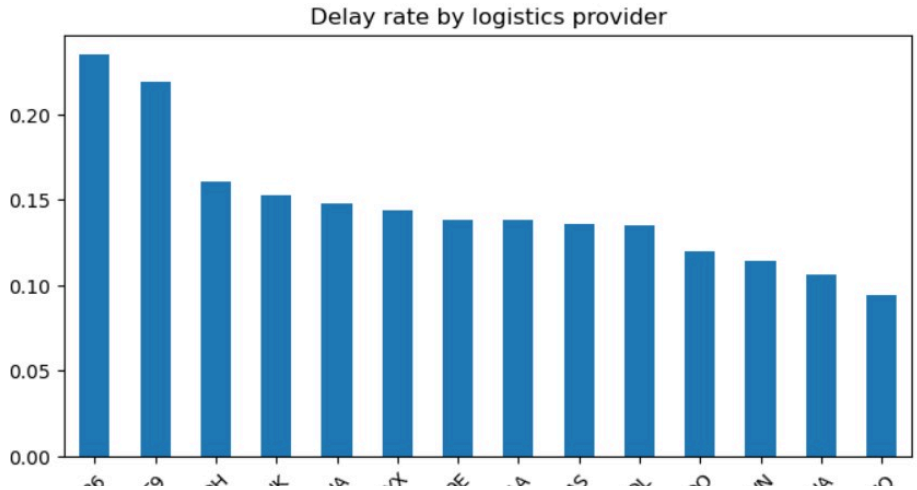
בפרויקט בוצע תהליך מלא של למידת מכונה: חקר נתונים, ניקוי והנדסת מסבירים, טיפול בחוסרים ובחריגים, קידוד משתנים קטגוריאליים, נרמול, הרצת מודלים, הערכת ביצועים והפקת תחזיות.

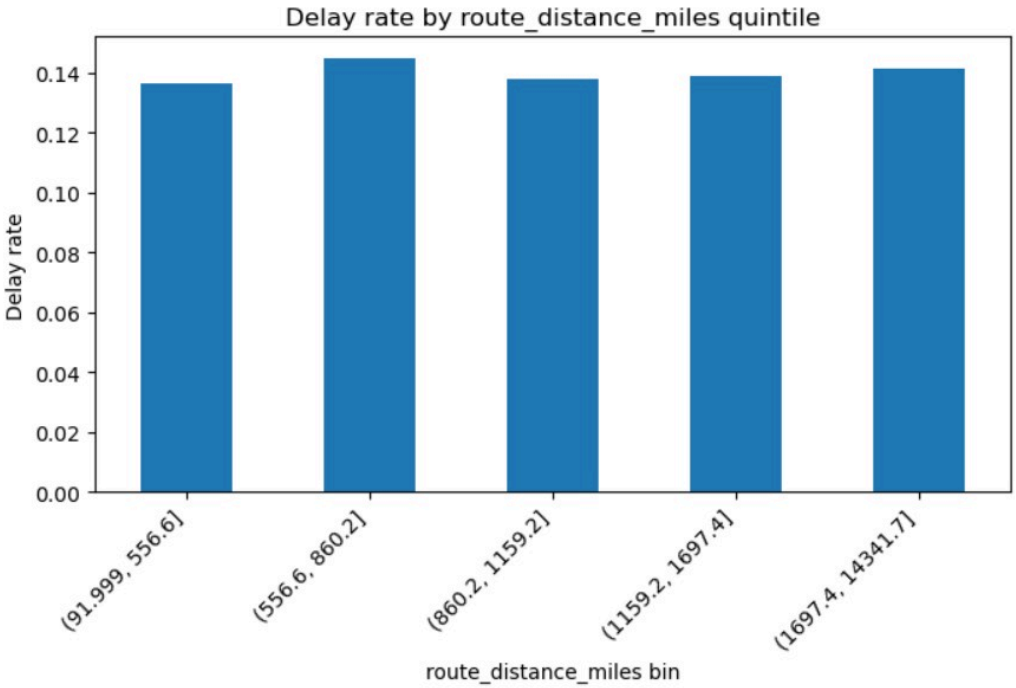
התובנה המרכזית היא שעיכובים צפויים, ובמיוחד עיכוב יציאה צפוי ועיכוב קודם, הם המסבירים המשמעותיים ביותר לחיזוי איחור משמעותי. לעומת זאת, מרחק המסלול וזמן הנסיעה המתוכנן תרמו מעט יחסית.

כל המודלים השיגו ביצועים גבוהים, אך Random Forest נבחר להגשה הסופית בשל שילוב של ביצועי AUC גבוהים, יציבות ויכולת הכללה. לא נמצאה עדות משמעותית להתאמת יתר, והתחזיות הסופיות נשמרו בקובץ CSV בפורמט הנדרש.

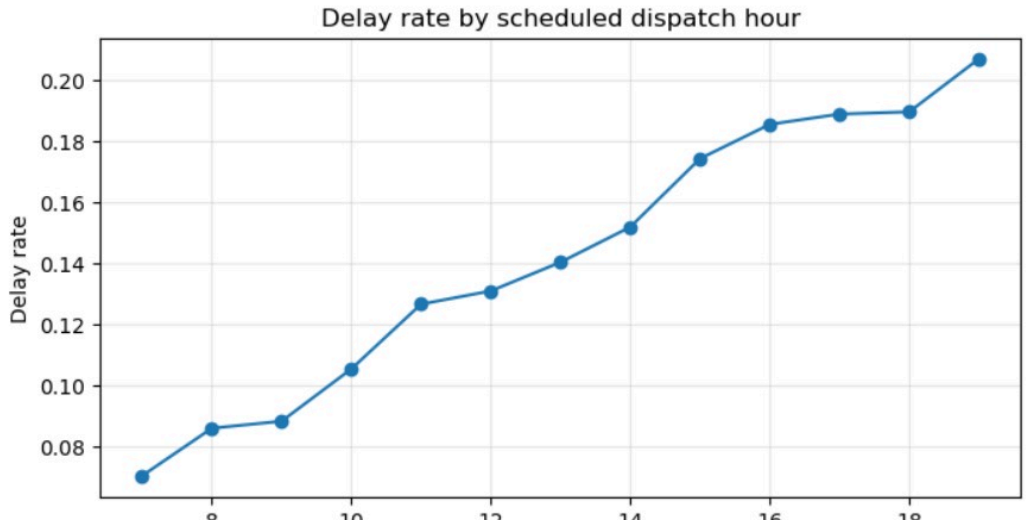


הגרף מציג את מספר ההעברות שלא התעכבו לעומת מספר ההעברות שהתעכבו ביותר מ-30 דקות. ניתן לראות כי המחלקה המאחרת קטנה משמעותית מהמחלקה שאינה מאחרת, ולכן נעשה שימוש במדד ROC-AUC ולא רק ב-Accuracy.

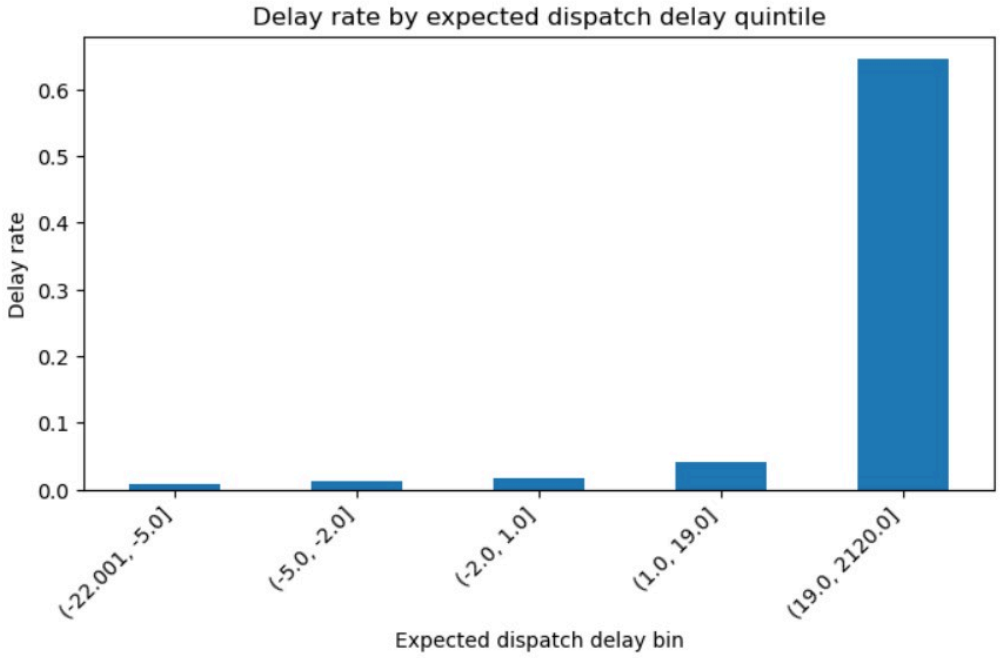




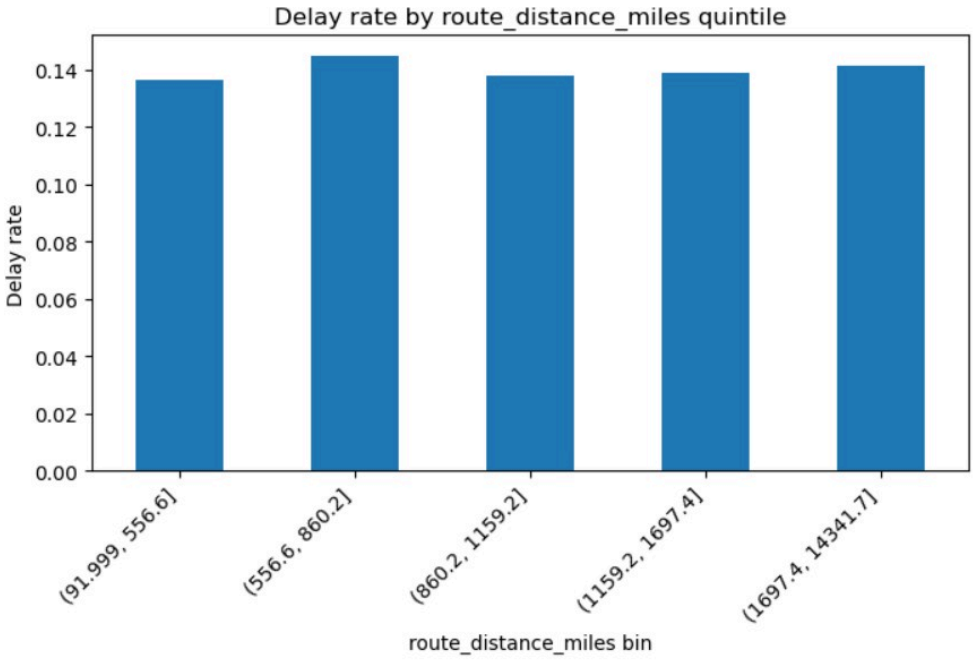
הגרפים מציגים הבדלים בשיעור האיחור בין ספקים לוגיסטיים ואזורים גיאוגרפיים. ניתן לראות כי יש ספקים ואזורים שבהם שיעור האיחור גבוה יותר, ולכן משתנים אלו עשויים להיות שימושיים לחיזוי.



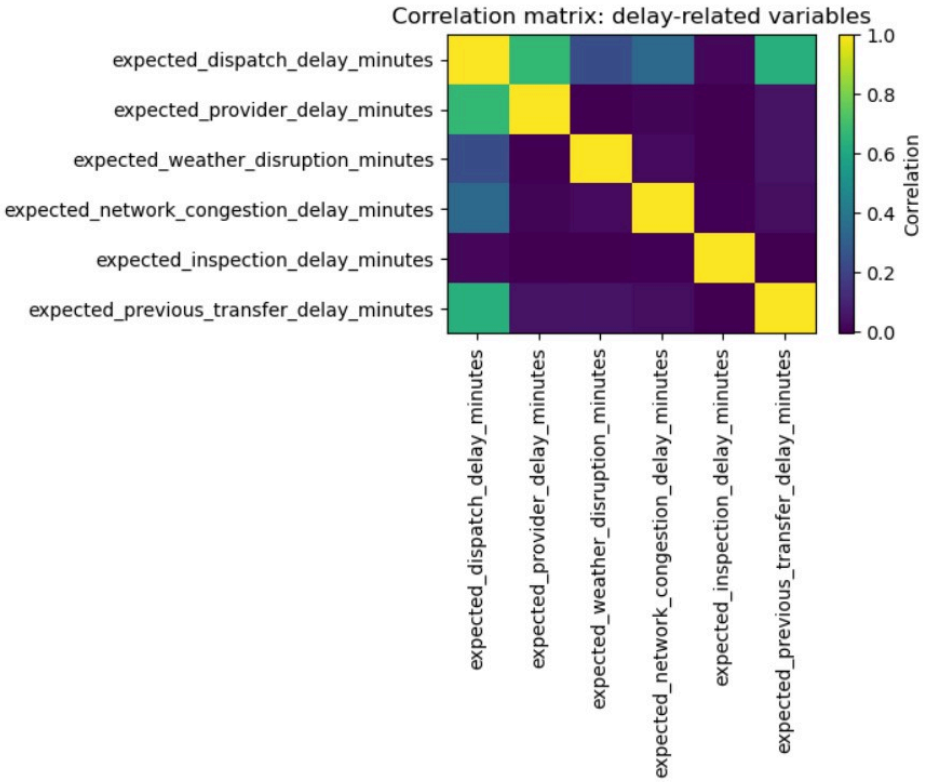
הגרף מציג עלייה ברורה בשיעור האיחור לאורך היום. בשעות הבוקר שיעור האיחור נמוך יחסית, ובשעות הערב הוא גבוה יותר. לכן שעת היציאה המתוכננת נראית כמשתנה משמעותי.



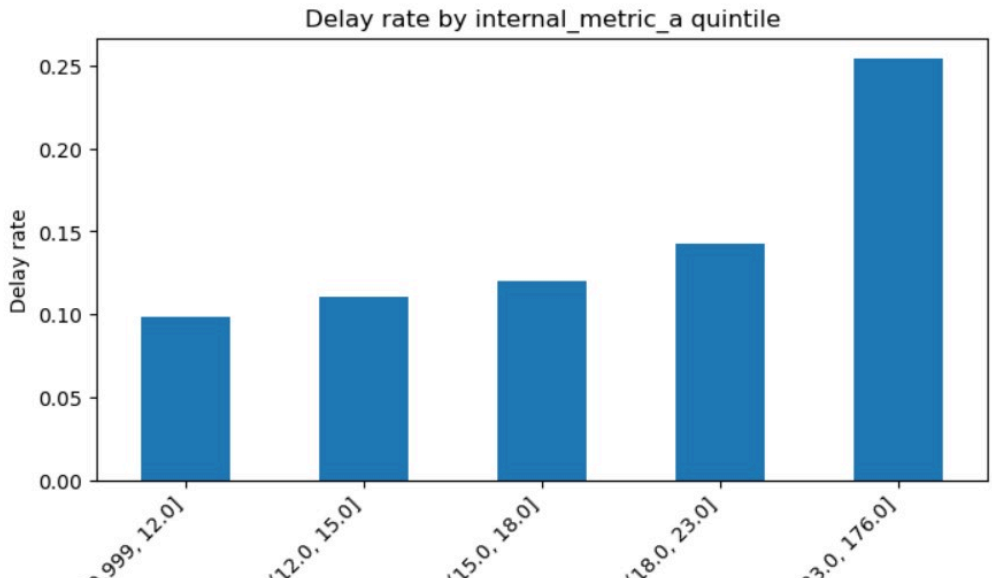
הגרף מציג קשר חזק בין expected_dispatch_delay_minutes לבין ההסתברות לאיחור משמעותי. בקבוצות הנמוכות שיעור האיחור קרוב ל-1% עד 4%, ואילו בקבוצה הגבוהה ביותר שיעור האיחור מגיע לכ-64.7%.



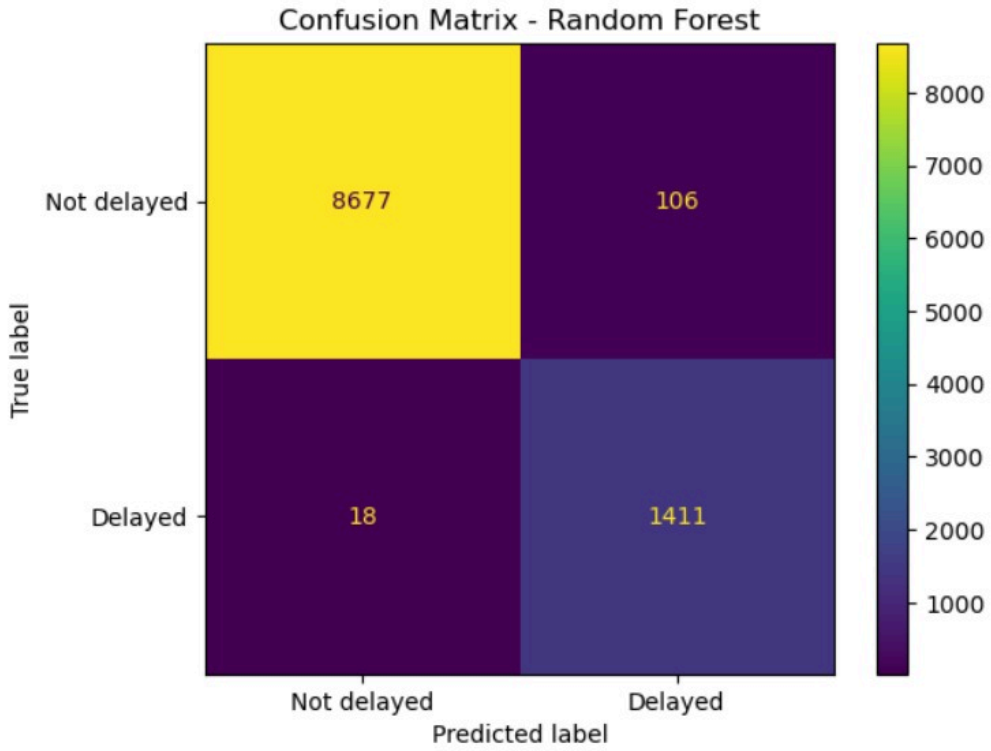
הגרף מציג כי שיעור האיחור כמעט אינו משתנה בין קבוצות מרחק שונות. לכן נראה כי מרחק המסלול אינו מסביר מרכזי לחיזוי האיחור.



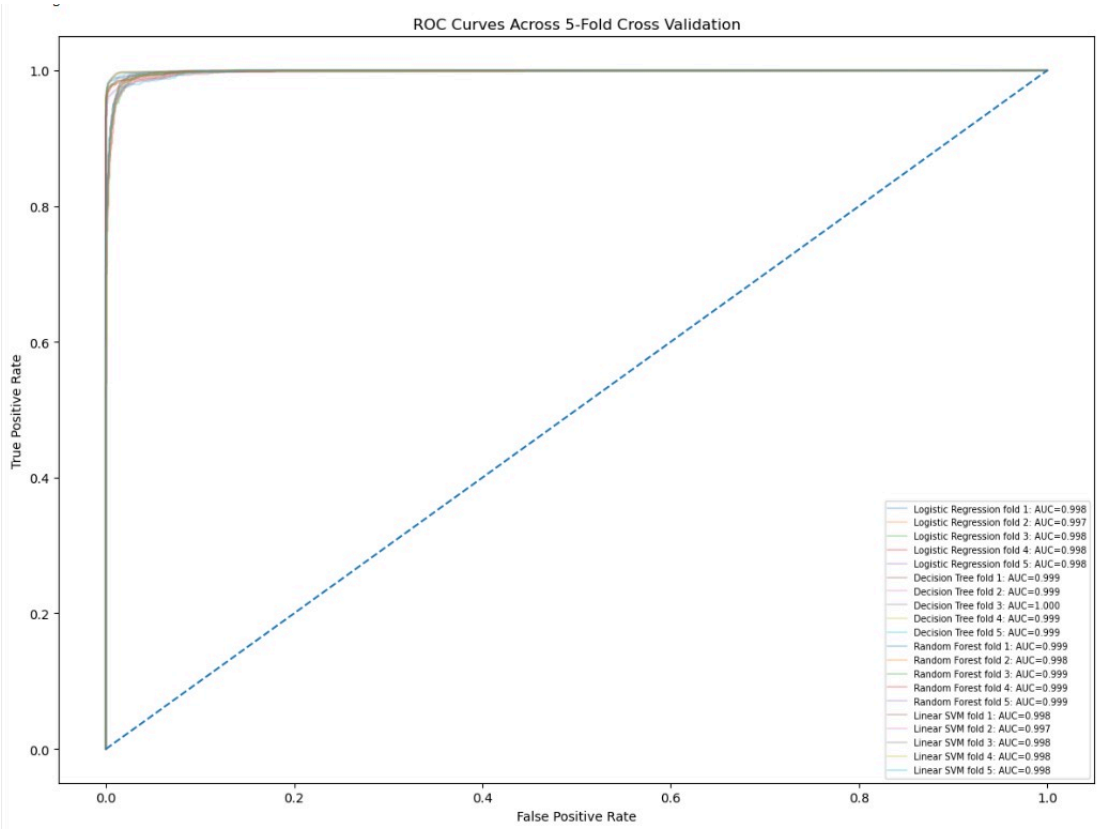
מטריצת הקורלציות מציגה קשרים בין סוגי עיכובים שונים. נמצאו קשרים חזקים יחסית בין עיכוב יציאה צפוי, עיכוב ספק צפוי ועיכוב קודם.



הגרפים מציגים כי חלק מהמשתנים האנונימיים, במיוחד internal_metric_a, מראים הבדלים בין העברות מאחרות לבין העברות שאינן מאחרות. לכן חלק מהמסבירים האנונימיים נשמרו במודל.



מטריצת הבלבול מציגה את מספר הסיווגים הנכונים והשגויים של המודל. המודל הצליח לזהות היטב גם העברות מאחרות וגם העברות שאינן מאחרות, עם מספר נמוך יחסית של טעויות.



עקומות ה-ROC מציגות את ביצועי המודלים בכל Fold של ה-Cross Validation. העקומות קרובות לפינה השמאלית-עליונה, מה שמצביע על יכולת סיווג גבוהה ויציבה.